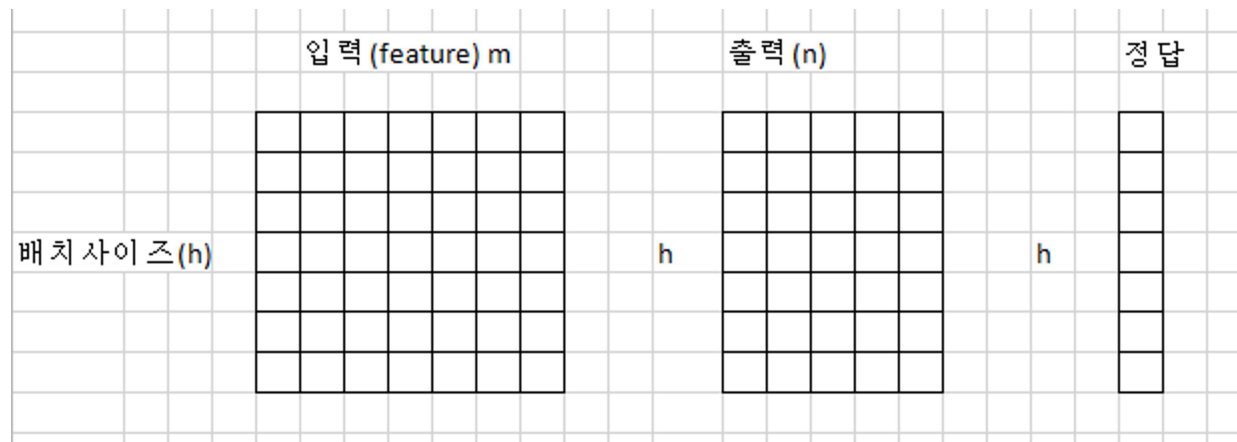


## 07. 행렬 연산

2020년 12월 31일 목요일 오전 11:03



### 1. 행렬을 이용한 순전파

- 입력  $x$ , 가중치  $w$  라 했을 때

$$XW = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1m} \\ x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ x_{h1} & x_{h2} & \cdots & x_{hm} \end{bmatrix} \begin{bmatrix} w_{11} & w_{12} & \cdots & w_{1n} \\ w_{21} & w_{22} & \cdots & w_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{m1} & w_{m2} & \cdots & w_{mn} \end{bmatrix}$$
$$= \begin{bmatrix} \sum_{k=1}^m x_{1k}w_{k1} & \sum_{k=1}^m x_{1k}w_{k2} & \cdots & \sum_{k=1}^m x_{1k}w_{kn} \\ \sum_{k=1}^m x_{2k}w_{k1} & \sum_{k=1}^m x_{2k}w_{k2} & \cdots & \sum_{k=1}^m x_{2k}w_{kn} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{k=1}^m x_{hk}w_{k1} & \sum_{k=1}^m x_{hk}w_{k2} & \cdots & \sum_{k=1}^m x_{hk}w_{kn} \end{bmatrix}$$

행 수가 배치 사이즈(h), 열 수가 출력 뉴런(노드)의 수(n)

- bias 는 다음과 같은 벡터인데, 계산 시 넘파이의 브로드캐스트 기능을 이용

$$\vec{b} = (b_1, b_2, \dots, b_n)$$

- bias 까지 더한 행렬의 모습은 아래와 같음  
bias = 출력 수(n)

numpy는 element-wise 사칙연산함  
2개의 shape이 동일한 경우 가능

브로드캐스트 기능은,  
 $A(3 \times 3M)$ 과  $B(1 \times 3M)$ 을  
 $A(3 \times 3M)$ 과  $B[3, (1 \times 3M)]$ 으로 계산해줌

$$U = \begin{bmatrix} \sum_{k=1}^m x_{1k}w_{k1} + b_1 & \sum_{k=1}^m x_{1k}w_{k2} + b_2 & \cdots & \sum_{k=1}^m x_{1k}w_{kn} + b_n \\ \sum_{k=1}^m x_{2k}w_{k1} + b_1 & \sum_{k=1}^m x_{2k}w_{k2} + b_2 & \cdots & \sum_{k=1}^m x_{2k}w_{kn} + b_n \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{k=1}^m x_{hk}w_{k1} + b_1 & \sum_{k=1}^m x_{hk}w_{k2} + b_2 & \cdots & \sum_{k=1}^m x_{hk}w_{kn} + b_n \end{bmatrix}$$

- 이 행렬의 각 원소는 활성화 함수 f 로 처리하고 출력 y를 다음과 같이 구함

$$Y = f(U) = \begin{bmatrix} f(\sum_{k=1}^m x_{1k}w_{k1} + b_1) & f(\sum_{k=1}^m x_{1k}w_{k2} + b_2) & \cdots & f(\sum_{k=1}^m x_{1k}w_{kn} + b_n) \\ f(\sum_{k=1}^m x_{2k}w_{k1} + b_1) & f(\sum_{k=1}^m x_{2k}w_{k2} + b_2) & \cdots & f(\sum_{k=1}^m x_{2k}w_{kn} + b_n) \\ \vdots & \vdots & \ddots & \vdots \\ f(\sum_{k=1}^m x_{hk}w_{k1} + b_1) & f(\sum_{k=1}^m x_{hk}w_{k2} + b_2) & \cdots & f(\sum_{k=1}^m x_{hk}w_{kn} + b_n) \end{bmatrix}$$

층의 출력 y는 h x n, 즉 배치 사이즈 x 뉴런(노드) 수 행렬이 됨

위의 연산을 넘파이를 이용하여 표현하면 다음과 같이 간단히 정리됨

\*\* 활성화 함수가 시그모이드인 경우

```
u = np.dot(x, w) + b
y = 1 / (1+np.exp(-u))
```

자동으로 numpy 브로드캐스팅되어 u 출력

## 2. 행렬을 이용한 역전파

- $\delta$  의 행렬  $\Delta$  는 다음과 같음

$$\Delta = \begin{bmatrix} \delta_{11} & \delta_{12} & \cdots & \delta_{1n} \\ \delta_{21} & \delta_{22} & \cdots & \delta_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \delta_{h1} & \delta_{h2} & \cdots & \delta_{hn} \end{bmatrix}$$

$\Delta$  는 층의 출력 y와 동일하게 h x n, 즉 배치 사이즈 x 뉴런(노드) 수 행렬임

- $\partial w_{ij}$  는 다음과 같다.

$$\partial w_{ij} = \frac{\partial E}{\partial w_{ij}} = y_i \delta_j$$

앞 층의 출력  $y_i$  는 현재 층의 입력과 같으므로 이 후 행렬식에서 y 대신 x로 표기할 것임

배치 사이즈를 처리하기 위해 구한 기울기값을 모두 더해야 함, 다음과 같은 식으로 정리됨

$$\sum_{k=1}^h \frac{\partial E_k}{\partial w_{ij}}$$

● 이상의 과정을 거쳐 배치를 고려한 가중치의 기울기 행렬  $\partial W$  는 다음과 같음

$$\partial W = X^T \Delta = \begin{bmatrix} x_{11} & x_{21} & \cdots & x_{h1} \\ x_{12} & x_{22} & \cdots & x_{h2} \\ \vdots & \vdots & \ddots & \vdots \\ x_{1m} & x_{2m} & \cdots & x_{hm} \end{bmatrix} \begin{bmatrix} \delta_{11} & \delta_{12} & \cdots & \delta_{1n} \\ \delta_{21} & \delta_{22} & \cdots & \delta_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \delta_{h1} & \delta_{h2} & \cdots & \delta_{hn} \end{bmatrix} \quad \delta : \text{배치수}h * \text{출력}n$$

$$= \begin{bmatrix} \sum_{k=1}^h x_{k1} \delta_{k1} & \sum_{k=1}^h x_{k1} \delta_{k2} & \cdots & \sum_{k=1}^h x_{k1} \delta_{kn} \\ \sum_{k=1}^h x_{k2} \delta_{k1} & \sum_{k=1}^h x_{k2} \delta_{k2} & \cdots & \sum_{k=1}^h x_{k2} \delta_{kn} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{k=1}^h x_{km} \delta_{k1} & \sum_{k=1}^h x_{km} \delta_{k2} & \cdots & \sum_{k=1}^h x_{km} \delta_{kn} \end{bmatrix}$$

x 와  $\Delta$ 의 행렬 곱을 위해  $X^T$  처럼 x를 전치시켜 앞쪽 행렬의 컬럼 수와 뒤쪽 행렬의 로우 수를 맞춰야 함

결과적으로 얻게 되는 행렬의 각 원소는 배치 내의 총합을 구한 것

이 행렬의 크기는  $m \times n$  이고 w의 크기와 일치

위 행렬 곱을 파이썬 코드로 나타내면 다음과 같음

`grad_w = np.dot(x.T, delta)`      오차는 가중치 기울기 행렬

grad\_w는 가중치 기울기 행렬  $\partial W$  이고 x는 입력 행렬 x, delta는  $\delta$ 의 행렬  $\Delta$ 를 나타냄

● bias의 기울기는 다음의 식을 이용해 구함

$$\partial b_j = \delta_j$$

배치를 고려한 기울기는 다음과 같이  $\delta$ 를 배치 내에서 모두 더함

$$\sum_{i=1}^h \frac{\partial E_k}{\partial b_j}$$

위 식을 파이썬 코드로 나타내면 다음과 같음

```
grad_b = np.sum(delta, axis=0)
```

● 앞 층의 출력 기울기(현재 층의 입력 기울기)는 다음의 식과 같음

$$\partial y_i = \sum_{r=1}^n \delta_r w_{ir}$$

가중치 기울기와 마찬가지로 앞 층의 출력  $y_i$  는 현재 층의 입력과 같기 때문에  $y$ 를  $x$ 로 바꾸어 표기

$\partial y$  를 배치에 고려한 행렬을  $\partial X$  로 하며 다음과 같이 정리됨

$$\begin{aligned} \partial X = \Delta W^T &= \begin{bmatrix} \delta_{11} & \delta_{12} & \cdots & \delta_{1n} \\ \delta_{21} & \delta_{22} & \cdots & \delta_{2n} \\ \vdots & \vdots & \square & \vdots \\ \delta_{h1} & \delta_{h2} & \cdots & \delta_{hn} \end{bmatrix} \begin{bmatrix} w_{11} & w_{21} & \cdots & w_{m1} \\ w_{12} & w_{22} & \cdots & w_{m2} \\ \vdots & \vdots & \square & \vdots \\ w_{1n} & w_{2n} & \cdots & w_{mn} \end{bmatrix} \\ &= \begin{bmatrix} \sum_{k=1}^n \delta_{1k} w_{1k} & \sum_{k=1}^n \delta_{1k} w_{2k} & \cdots & \sum_{k=1}^n \delta_{1k} w_{mk} \\ \sum_{k=1}^n \delta_{2k} w_{1k} & \sum_{k=1}^n \delta_{2k} w_{2k} & \cdots & \sum_{k=1}^n \delta_{2k} w_{mk} \\ \vdots & \vdots & \square & \vdots \\ \sum_{k=1}^n \delta_{hk} w_{1k} & \sum_{k=1}^n \delta_{hk} w_{2k} & \cdots & \sum_{k=1}^n \delta_{hk} w_{mk} \end{bmatrix} \end{aligned}$$

$\Delta$ 와  $w$ 의 행렬 곱을 위해  $W^T$  와 같이  $w$ 를 전치시키며, 이를 통해  $\Delta$ 의 컬럼 수와  $w$ 의 로우 수가 일치되고 행렬 곱을 할 수 있음

결과적으로 얻게 되는 행렬의 각 원소는 현재 층에 있는 모든 뉴런(노드)의 결과를 합한 것이 됨

위 식을 파이썬 코드로 표현하면 다음과 같음

```
grad_x = np.dot(delta, w.T)
```